Recherche textuelle

Table des matières

1) Introduction

Les algorithmes qui permettent de trouver une sous-chaîne de caractères dans une chaîne de caractères plus grande sont des grands classiques de l'algorithmique.

Un des secteurs qui utilise le plus cette recherche textuelle est le domaine de la bioinformatique notamment dans l'analyse des informations génétiques. Cette information génétique présente dans nos cellules est portée par les molécules d'ADN et permet la fabrication des protéines. Ces molécules d'ADN sont, entre autres, composées de bases azotées ayant pour noms : Adénine (représenté par un A), Thymine (représenté par un T), Guanine (représenté par un G) et Cytosine (représenté par un C).

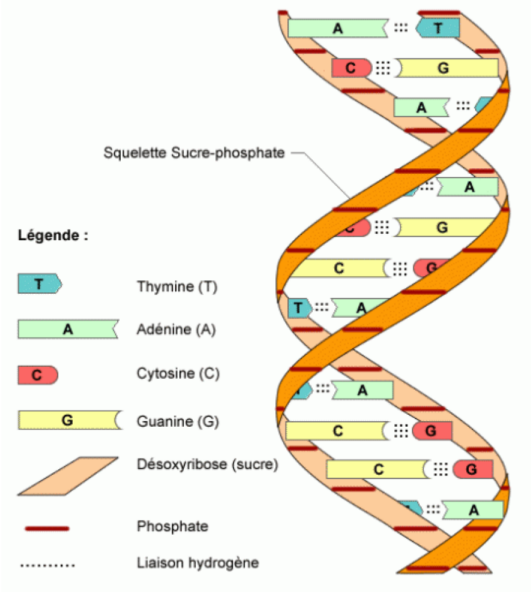

molécule d'ADN

Il est souvent nécessaire de détecter la présence de certains enchaînements de bases azotées (dans la plupart des cas un triplet de bases azotées code pour 1 acide aminé et la combinaison d'acides aminés forme une protéine).

Comment fonctionne ces algorithmes ?

L'objectif, ici, est de construire des algorithmes de recherche textuelle, d'en comprendre les principes et de les comparer. Nous étudierons également l'algorithme de Boyer-Moore.

Tout comme la plupart des applications, Python possède sa propre méthode de recherche, ce script affiche la présence ou non d'une occurrence. (mot) dans un texte (phrase).

```
phrase="Ceci n'est que la phrase qui nous sert d'exemple"
mot1="qui"
mot2="quiche"

print(mot1 in phrase)
print(mot2 in phrase)
```

Là encore, on peut se demander comment cela fonctionne...

2) Une approche "naïve"

Les chaînes de caractères font parties des séquences, c'est à dire que chaque caractère est atteignable par son indice dans la chaîne.

Par exemple :

```
# affiche le 3ème caractère de la chaîne
print(phrase[2])
# affiche le dernier
print(phrase[-1])
# affiche la longueur de la chaîne
print(len(phrase))
```

Pour savoir si un mot est dans une phrase, la méthode qui nous vient à l'esprit est la suivante :

On parcourt le texte d'indice en indice depuis le début du texte en vérifiant à chaque pas si les lettres du mot coïncident.

```
x
Ceci n'est que la phrase qui nous sert d'exemple
qui

 x
Ceci n'est que la phrase qui nous sert d'exemple
 qui

  x
Ceci n'est que la phrase qui nous sert d'exemple
  qui

  ...
          oox
Ceci n'est que la phrase qui nous sert d'exemple
          qui
  ...

                        ooo
Ceci n'est que la phrase qui nous sert d'exemple
                        qui
```

Fin de la recherche.

Exercice 1 :

1. Écrire une fonction `occurrence` qui renvoie si un mot est trouvée dans une phrase à partir d'un indice i. Cette fonction prend en arguments le mot (l'occurrence), la phrase (le texte), et la position du mot dans le texte(l'indice i. Celle-ci retournera un booléen.
2. Vérifier que `occurrence(mot1, phrase, 2)` renvoie Faux.
3. Pour quelle valeur de i `occurrence(mot1, phrase, i)` renvoie Vrai

Exercice 2 :

Écrire une fonction recherche qui prend en paramètres un mot et un texte et qui renvoie l'indice où apparaît le mot dans le texte et "occurrence non trouvée" si le mot n'est pas dans le texte. (On utilisera la fonction occurrence donnée plus haut)

Appliquer cette fonction à la phrase2, qui représente une séquence d'un brin d'ADN, avec l'occurrence 'CGGCAG' (La fonction doit renvoyer 15). La phrase2 se trouve dans l'espace des classes sur l'ENT.

Exercice 3 :

Modifier la fonction recherche (en recherches...) pour que cette fois-ci elle renvoie la liste des indices où apparaît le mot dans le texte.

Pour phrase2 et mot3 ("ACG"), vous devez obtenir : [12, 137, 205, 325, 360], ce qui signifie que le mot 'ACG' apparaît 5 fois. (aux indices indiqués dans la liste)

Exercice 4 : Avec un texte un peu plus long

Le fichier vh.txt contient le premier tome des misérables de Victor Hugo.

Il faut le placer dans le même dossier que ce programme.

Le code ci-dessous mesure en seconde le temps d'exécution de 5 appels de la fonction recherches(mot,texte), pour le mot 'Valjean' et le texte 'tome1'.

Vous devriez trouver une valeur entre 1,10 et 1,13 ...

Que signifie le 196 affiché ?

```
from timeit import default_timer as timer
with open('vh.txt','r') as vh:
    tome1 = vh.read()

d=timer()
for i in range(5):
    print(len(recherches('Valjean',tome1)))
f=timer()
print(f-d)
```

3) Algorithme de Boyer-Moore

Dans la méthode naïve, à chaque étape on se décale d'un cran vers la droite. C'est en "jouant" sur ce décalage que l'on peut améliorer la méthode.

3.1) Le principe de l'algorithme

L'objectif est de rechercher l'occurrence CGGCTG dans la séquence ATAACAGGAGTAAATAACGGCTGGAGTAAATA.

On aligne et on teste l'occurrence par la droite :

```
      x
  CGGCTG
  ATAACAGGAGTAAATAACGGCTGGAGTAAATA
```

Comme G et A ne correspondent pas et qu'il n'y a pas de A dans l'occurrence on décale l'occurrence de 6 rangs (la longueur de l'occurrence).

```
          x
       CGGCTG
 ATAACAGGAGTAAATAACGGCTGGAGTAAATA
```

On est dans une situation similaire, et en deux étapes on obtient ce que la méthode naïve aurait fait en 12 étapes !

```
                x
             CGGCTG
   ATAACAGGAGTAAATAACGGCTGGAGTAAATA
```

Dans cette situation, le G et le C ne correspondent pas mais il y a un C dans l'occurrence, on décalera donc l'occurrence de 2 rangs (place du premier C depuis la fin de l'occurrence)

On obtient donc :

```
               xo
            CGGCTG
 ATAACAGGAGTAAATAACGGCTGGAGTAAATA
```

Cette fois-ci les G correspondent puis T et G ne correspondent pas, or il y a un G (avant le T) dans l'occurrence.

On décale donc de 3 rangs.

On obtient donc :

```
                ooooooo
                CGGCTG
 ATAACAGGAGTAAATAACGGCTGGAGTAAATA
```

On trouve une correspondance complète.

Pour continuer la recherche il suffit de la relancer un rang plus loin...

En appliquant à chaque étape un décalage adapté, on accélère grandement le processus.

3.2) Une première fonction

Exercice 5 :

Que fait la fonction ci-dessous Expliquer la valeur de la clé 'a'.

```
def dico(mot):
    dico={}
    m=len(mot)
    for i in range(m-1):
        dico[mot[i]]=m-1-i
    return dico

dico("Valjean")
```

3.3) L'algorithme

Voici l'algorithme qui réalise le processus décrit plus haut :

Fonction boyerMoore(mot,texte) :

- longText ← longueur du texte
- longMot ← longueur du mot
- positions ← []
- decalage ← dico(mot)
- Tant que $i \leq$ longText-longMot :
  - Si texte[i+j] $\neq$ mot[j] :
    - Si texte[i+j]est une clé de decalage et que sa valeur est inférieure à j
      - i←i+decalage[i+j]
    - Sinon :
      - i←i+j+1
    - trouve ← False
    - Break
  - Sinon :
    - trouve← True
  - Si trouve est vrai :
    - on ajoute i à positions
    - i ← i+1
- renvoyer positions

Exercice 6 :

1. Implémenter cette fonction en commentant les différentes parties.
2. Appliquer le sur le texte de Victor Hugo avec le mot 'Valjean' pour vérifier son bon fonctionnement.
3. Faire afficher le temps d'exécution de 5 appels de la fonction Boyer_Moore. Qu'en déduisez - vous ?

Exercice 7 :

Reprendre la comparaison avec la recherche de l'occurrence 'e'

4) Conclusion

L'algorithme de Boyer-Moore fut inventé en 1977. Il peut être encore amélioré avec plusieurs tables de saut, chacune correspondant au saut possible en fonction du caractère testé dans la clé. Cet ajout de table présente un intérêt pour les recherches avec une clé de taille importante.